

CNC Tool Life AI Ecosystem — Mini Project Progress 3

ระบบพยากรณ์อายุใช้งานที่เหลือของดอกกัดจากสัญญาณเครื่องจักร (Time-series) ร่วมกับการประเมินสภาพคมตัดจากภาพ (Vision)

WTN-A12 · 241-353 AI Ecosystem


กลุ่ม:

สมาชิก:

4 ตุลาคม 2569

1. Dataflow and Ecosystem Design

โจทย์: ดอกกัด CNC สึกหรือสะสมจนต้องเปลี่ยน ถ้าเปลี่ยนเร็วเกินไปจะทั้งอายุดอกและหยุดเครื่องบ่อย ถ้าเปลี่ยนช้าเกินไป ผิวด้านจะเสียหรือดอกแตก ระบบจึงต้องบอก “อายุใช้งานที่เหลือ (RUL)” ระหว่างผลิต โดยใช้ข้อมูลที่เครื่องบันทึกเองเท่านั้น ไม่ต้องหยุดเครื่องวัดรอยสึก VB ระบบนี้ประกอบด้วย AI 2 ตัว: (1) Time-series RUL service พยากรณ์จากสัญญาณแรง/แรงบิดทุกแนวตัดแบบเวลาจริง (2) Vision service จำแนกสภาพคมตัดจากภาพหน้าคมมีด (SHARP/USED/DULLED) ใช้ยืนยันเมื่อหยุดเครื่องหรือถอดดอก และเป็นแหล่ง label ของการ retrain ในอนาคต



รูปที่ 1 Ecosystem: Time-series RUL service ทำงานแบบเวลาจริง (แถวบน) · ที่เก็บข้อมูลและโมเดล (MinIO เป็น model registry) · Vision service อยู่ระหว่างรวมระบบ · วงจร MLOps/retrain (แถวล่าง, แผน)

1.1 Dataflow ของเส้นทางออนไลน์ (Time-series RUL)

#	ขั้นตอน	ข้อมูล / การประมวลผล	ความถี่ / ขนาด	Component → ปลายทาง
1	รับสัญญาณ	Fx, Fy, Fz (dynamometer) + แรงบิด spindle, แรง/แรงบิดมอเตอร์แกน X/Y, ตำแหน่ง (controller) ของ 1 แนวตัด	25 kHz + 500 Hz · ≈ 4.4 s/แนว	Stream Gateway (.h5 จริง)
2	สัญญาณสด	ย่อเป็น 500 Hz, ≤ 50 จุด/สัญญาณ/เฟรม ส่งเฉพาะเครื่องที่ใช้เปิดดู	10 เฟรม/วินาที	WebSocket → Machine Monitoring
3	พีเจอร์รายแนว	ค่าเฉลี่ยในช่วงตัดเสถียร (y 5–90 mm) 7 ค่า → causal Hampel filter (ดูอดีตเท่านั้น) → % เปลี่ยนจากค่าตั้งต้นของดอก (29 แนวแรกหลัง break-in) + เวลาตัดสะสม + เครื่อง + ตำแหน่งแนวตัด	1 เวกเตอร์ 12 ค่า/แนว	runtime (โค้ดเดียวกับตอนฝึก)
4	พยากรณ์	หน้าต่าง 29 แนวล่าสุด (= 1 ชิ้นงาน = 1 คาบฤดูกาล) → GRU ensemble 5 ตัว → เวลาถึง VB 103 / 140 μm → ข้อจำกัดฟิสิกส์ T _{EOL} คงที่ → RUL, P10–P90, สถานะ, คำแนะนำ	~ 1.6 ms/แนว (numpy)	WebSocket + REST → Dashboard
5	การตัดสินใจ	คำแนะนำยกระดับ → alarm (INFO/WARNING/CRITICAL); REPLACE NOW → interlock หยุดปั๊ม รอผู้ควบคุม “ถอดดอก/ตัดต่อ” → บันทึก audit	ตามเหตุการณ์	PostgreSQL (alarms, audit)
6	หลังถอดดอก	เปิดเผย VB จริง (วัดหลังถอดดอก) → เทียบสิ่งที่ระบบบอกระหว่างใช้งาน: MAE, เวลาที่สิ่งเปลี่ยนเทียบหมอดอายุจริง → label สำหรับ retrain	1 ครั้ง/ดอก	Reports, JSONL → (แผน) MinIO datasets
7	วงจรชีวิตโมเดล	ฝึกออฟไลน์ → npz (น้ำหนัก + เวกเตอร์ทดสอบตัวเอง) + json (อินพุต, เกณฑ์, ดอกฝึก/ดอกสแกน, ช่วงความเชื่อมั่น, sha256) → MinIO → backend ตรวจสอบ sha256 + self-test ก่อนใช้	114 KB/เวอร์ชัน	MinIO models/tool-ru1/


- **อินพุตที่โรงงานมีจริง:** ไม่ใช่ VB เป็นอินพุต (ต้องถอดดอกไปส่งกล่อง) VB ใช้เป็น label ตอนฝึกเท่านั้น
- **Causal ทั้งเส้นทาง + โค้ดเดียวกัน:** ตัวกรอง outlier, พีเจอร์ และข้อจำกัดฟิสิกส์ใช้เฉพาะข้อมูลอดีต ไฟล์ runtime.py ใน backend ตรงกับที่ใช้สร้างชุดฝึก (มี test บังคับ)
- **ไม่สปอยข้อมูล:** ดอกที่สตรีมไม่เคยใช้ฝึก ไม่ส่ง VB, RUL จริง หรือชื่อไฟล์ไปหน้าเว็บจนกว่าจะถอดดอก

- **Model registry บน MinIO:** แยกเวอร์ชัน มี latest.json สลับ/ย้อนเวอร์ชันได้ ไม่มีโมเดลสำรองหรือค่าสมมุติ ถ้าโหลตไม่ได้จะแจ้งว่าไม่พร้อม
- **Human-in-the-loop:** AI เป็นผู้แนะนำ คนตัดสินใจ (interlock + audit) และ vision ใช้ยืนยันสภาพคมตัด
- **Modular:** backend แบ่งตาม feature ใน docker compose (FastAPI, React, MinIO, PostgreSQL, Redis/ARQ, MLflow) จึงเพิ่ม vision/retrain worker ได้โดยไม่กระทบ service เดิม

2.1 คำถามการทดลองและสมมติฐาน

#	สมมติฐาน	การทดลองที่ใช้ตอบ
H1	แบบจำลองอนุกรมเวลาที่ พยากรณ์ RUL โดยตรง แม่นกว่าการพยากรณ์ VB ก่อนแล้วหาจุดตัดเกณฑ์ และไม่แยกว่าอายุเฉลี่ยของเครื่อง	LOTO: GRU direct-RUL vs StateSpace vs Fleet reference
H2	ข้อจำกัดฟิสิกส์ “เวลาหมดอายุของดอกคองที่” ลดความคลาดและการพยากรณ์อายุเกินจริง	Ablation: เปิด/ปิด EOLTracker
H3	เซนเซอร์ให้ข้อมูลเพิ่มจากเวลาตัด + เครื่อง เมื่อควบคุม overfitting ได้	Ablation อินพุต + nested selection ของ noise augmentation
H4	Vision แยกสภาพคมตัดของดอกที่ไม่เคยเห็นได้ $\geq 80\%$ (top-1)	YOLOv8n-cls, held-out Tool 10
H5	ระบบสตรีมจริงให้ผลเหมือนการประเมินออฟไลน์ (ไม่มี train/serve skew)	Parity test + เล่น T3/T6/T9 ผ่านระบบจริงตามเวลาจริง

งาน	ชุดข้อมูล / label	การแบ่ง
Time-series RUL	LUH milling (Denkena et al., 2023): 9 ดอก × 3 เครื่อง, 6,418 แนวตัด, run-to-failure · label = เวลาที่ VB ข้าม 140 μm (หมดอายุ) และ 103 μm (เริ่มสึกเร่งจาก SETAR) · VB ตามนิยาม ISO 8688-2	(1) ตามดอก: ฟีก production T1,T2,T4,T5,T7,T8 · สงวน T3,T6,T9 ไว้สตรีม (2) Leave-one-tool-out 9 รอบ (3) 80:20 ตามเวลา ภายในดอก (20% ทำย = ช่วงตัดสินใจ: 4,750 / 1,184 แนว) (4) Leave-one-machine-out = เครื่องใหม่
Vision	Nonastreda tool/ : ภาพกล้องจุลทรรศน์หน้าคมมีด 3 คลาส (sharp / used / dulled)	ฟีก 456 ภาพ (ดอก 1–9) · ทดสอบ 56 ภาพของ Tool 10 ที่ไม่เคยเห็น (ไม่สุ่มแบ่งภาพ เพื่อกันการจำจำนำเฉพาะดอก)




2.3 แบบจำลอง ตัวแปร และการควบคุมการทดลอง

- **Time-series (3 แบบ):** *Fleet reference* = อายุเฉลี่ยของเครื่อง - เวลาตัด (baseline) · *StateSpace* = VB แผง + Gamma increments + particle filter 4,000 อนุภาค → เวลาข้ามเกณฑ์ (ทางอ้อม) · *GRU direct-RUL* = GRU 1 ชั้น hidden 32 อ่านหน้าต่างต่าง 29 แนว × 12 ฟิเจอร์ → softplus 2 หัว, loss L1, Adam 30 epochs, ensemble 3 ตัว (production 5 ตัว)
- **ตัวแปรต้นที่ทดสอบ:** รูปแบบ GRU 4 แบบ (direct / +noise $\sigma=1$ / ปรับแก้อายุอ้างอิง / ทั้งคู่) เลือกแบบ **nested LOTO บนดอกฝัก 6 ดอกเท่านั้น** · ablation อินพุต (เวลา+เครื่อง / เซนเซอร์+เวลา / ครบ) · ข้อจำกัดฟิสิกส์เปิด/ปิด · การจัดการ outlier (causal / STL / ไม่จัดการ)
- **ควบคุม:** seed คงที่, normalization และช่วงความเชื่อมั่นคำนวณจากดอกฝักเท่านั้น, เงื่อนไขการตัดเดียวกันทุกดอก
- **Vision:** YOLOv8n-cls (transfer learning จาก ImageNet) 224×224, augmentation (flip, หมุน $\pm 10^\circ$, scale $\pm 10\%$, HSV), AdamW + weight decay $5e-4$, cosine LR + warmup 2 epochs, AMP, 20 epochs, บันทึกผลใน MLflow

RUL (นาฬิกาของเวลาตัด): MAE / RMSE / Bias ทั้งอายุและช่วง 20% ท้าย · %late = สัดส่วนแนวที่พยากรณ์อายุเกินจริง > 1 ชั้่นงาน (2.73 นาที) ซึ่งเป็นความเสี่ยงหลัก · accuracy / macro-F1 ของสถานะ · **decision replay** (เวลาที่สั่ง REPLACE_NOW เทียบหมดอายุจริง, % อายุ ดอกที่ใช้, เวลาที่แจ้งวางแผนล่วงหน้า) · ความครอบคลุมของ P10-P90 · Wilcoxon รายดอก **Vision:** top-1, macro-F1, precision/recall รายคลาส, latency · **ระบบ:** ความคลาดของจังหวัดสตรีม (วินาที/แนว), parity ระหว่าง backend กับออฟไลน์, pytest

2.5 ผลการทดลองถึงปัจจุบัน

RUL, leave-one-tool-out	MAE ทั้งอายุ	MAE 20% ทำย	%late	ดอกที่สวนไว้ (ไม่เคยใช้ฝึก)	T3	T6	T9
Fleet reference	1.16	0.90	0	MAE ของ RUL (นาที่)	2.29	1.63	0.55
StateSpace (ทางอ้อม)	1.58	1.75	13.3	REPLACE_NOW (นาที่)	50.9	77.9	49.6
GRU direct-RUL	1.11	0.91	0	หมดอายุจริง (นาที่)	57.9	84.0	53.5
· ไม่มีข้อจำกัดฟิสิกส์	1.28	1.28	0	ใช้อายุดอก	88%	93%	93%
· ไม่มีเซนเซอร์	1.31	0.94	0	Vision (Tool 10, 56 ภาพ)			ผล
· ไม่ใช้ noise (nested, 6 ดอก)	2.04	1.74	5.5	Top-1 / macro-F1	83.9% / 80.4%		
				SHARP recall · DULLED precision	100% · 100%		
				Latency (GPU / รวม I/O)	3.9 / 38 ms		



รูปที่ 3 RUL ที่ระบบรายงานระหว่างสตรึมดอกที่ไม่เคยใช้ฝึก (เส้นน้ำเงิน + ช่วง P10-P90) เทียบ RUL จริงที่เปิดเผยหลังถอดดอก (เส้นดำ) และเวลาที่สั่ง REPLACE_NOW (เส้นแดง)

ข้อสรุป: H1 ✓ (direct-RUL แม่นกว่าทางอ้อมชัดเจนและไม่เคยพยากรณ์เกินจริง แต่ชนะ baseline เพียงเล็กน้อย Wilcoxon p = 0.50 เพราะเงื่อนไขการตัดคงที่ อายุดอกในเครื่องเดียวกันต่างกันแค่ 0.7-3%) · H2 ✓ · H3 ✓ (เมื่อใช้ noise augmentation) · H4 ✓ (ผิดพลาดเฉพาะรอยต่อ USED/DULLED) · H5 ✓ (สตรึมจริง 4.41 s/แนว ตรงความยาวไฟล์ ผลรายแนวเท่ากับออฟไลน์ และเวลา REPLACE_NOW ของ T3/T6/T9 บนระบบจริงตรงกับตาราง pytest 5/5) · **ข้อจำกัด:** เครื่องใหม่ที่ไม่มีประวัติคลาด 11-24 นาที และข้อมูลมีเพียง 9 ดอก

2.6 การทดลองระยะถัดไป

1. **รวม Vision เข้าระบบ:** ย้ายโมเดล YOLOv8 ขึ้น MinIO/registry แบบเดียวกับ RUL, ต่อ vision worker กับหน้า Tool Image Wear และวัด end-to-end latency/accuracy บนภาพที่อัปโหลดจริง
2. **Retrain pipeline** **แผน** : trigger เมื่อมีดอกที่ถอดแล้ว ≥ N ดอก (label จาก VB หรือภาพที่วิศวกรยืนยัน) → ARQ GPU worker ฝึกใหม่ → **gate** = LOTO MAE ไม่แย่กว่าเวอร์ชันเดิม และ %late = 0 → shadow mode คู่กับเวอร์ชันเดิม → publish (MinIO + MLflow) → สลับ latest.json
3. **ทดสอบความทนทาน:** เครื่องใหม่ (few-shot calibration), drift ของสัญญาณ และเกณฑ์นโยบาย P10 ที่ต่างกัน (ต้นทุนดอก vs ความเสี่ยงงานเสีย)